

答辩 PPT 纲要

1. 项目背景

本文面向广告与商业化业务场景，围绕“内容资产规模大、更新频繁、形态多样、分散沉淀”的现实问题，设计并实现一套内容应用与管理平台。平台以内容全生命周期为主线，将内容管理、内容应用（检索与智能问答）、内容治理（质量闭环）与数据洞察（效果评估与反馈）进行一体化建设。

核心痛点归纳如下：

- 内容分散在不同业务线与系统中，缺乏统一内容模型与统一组织方式，复用成本高。
- 传统内容平台以页面浏览与人工检索为主，难以支撑高频咨询与智能问答入口。
- 随规模扩张出现重复、歧义、覆盖不足等质量问题，依赖人工维护难以长期支撑。
- 缺少“应用效果-问题定位-治理动作-复检回收”的数据闭环，难以持续迭代。

本文建设目标归纳如下：

- 统一管理：建立“空间-应用-类目-标签”的组织体系与多形态内容统一管理。
- 高效应用：在页面化展示与检索基础上，引入基于 RAG 的智能问答能力。
- 质量可控：围绕重复度、歧义度与覆盖度建立治理机制，并落地线上任务闭环。
- 数据驱动：通过事件采集与会话分析支撑评估与反馈，形成持续优化机制。

2. 技术综述

本节分为两部分：相关技术一览（表格）与项目中技术应用情况（列表）。

2.1 相关技术一览（表格形式）

下表用于在 PPT 中快速交代“平台依赖的关键技术组件及其作用”。

技术/组件	类别	核心作用（面向本项目）
RocketMQ	消息队列	解耦发布后的异步链路（索引更新、数据回收等），提升吞吐与稳定性
Elasticsearch（Lucene/BM25）	全文检索	关键词检索、结构化过滤、分页与高亮，支撑页面化展示与搜索
Embedding	表征学习	将 Query/切片转为向量，提升语义召回与长尾覆盖
Milvus（ANN/HNSW/IVF 等）	向量数据库	语义向量 TopK 检索与过滤，支撑问答证据召回

技术/组件	类别	核心作用（面向本项目）
RAG（检索增强生成）	应用范式	“召回-重排-生成”链路，提升问答可用性与可解释性
RRF（Reciprocal Rank Fusion）	融合重排	多通道召回结果融合与重排，提升相关性与稳定性
LLM（大模型服务）	智能能力	问题改写、回答生成、治理判别（重复/歧义/覆盖）与结构化输出
MySQL	关系型存储	组织、内容元数据、权限、审批、治理任务等结构化数据承载
MongoDB	文档存储	承载灵活结构内容（如案例详情等）
Redis	缓存/协调	权限结果缓存、热点读缓存、分布式锁等
Hive/数仓	离线计算	明细与宽表加工，支撑洞察指标与会话分析
SpringBoot	后端框架	按域拆分服务，承载核心业务能力与接口
React	前端框架	管理后台与前台界面实现

2.2 项目中技术应用情况（列表）

- RocketMQ：发布事件驱动索引更新与统计回收，主链路 with 异步链路解耦。
- Elasticsearch：承载列表/搜索等高频读场景，利用 Filter 进行状态、类目、标签与权限过滤。
- Milvus + Embedding：承载问答证据切片的向量召回，提高语义匹配与长尾覆盖。
- 多通道召回：ES 全文召回与向量召回并行，提升稳定性与覆盖率。
- RRF 重排：对多通道候选进行融合重排，按倒数排名累加得分并去重输出 TopN 证据。
- LLM 问答：对用户 Query 进行改写，并基于证据集合生成回答，输出携带引用以支持溯源。
- LLM 治理：用于重复/歧义判别与覆盖度判别，输出结构化结果以便落表与任务化。
- 权限体系：RBAC + content_auth 组合，覆盖管理端操作控制与读链路可见性控制。
- 数据洞察：统一事件模型采集 page/search/rag/llm 等链路数据，按 session_id/trace_id 做可追溯分析。


3. 系统设计（架构图与描述）

本节组织方式为“先总架构，再三视图，再关键流程”。PPT 中建议每张图配 1-2 句解释其表达对象与结论。

3.1 总体架构与三视图


系统总体架构用于说明平台的分层、模块边界与基础设施依赖。

- 系统架构图：说明入口层/服务层/基础设施层，以及四大核心域（内容管理、内容应用、内容治理、数据洞察）。




– 链接:../figure/figures-系统架构图.drawio.pdf


- 逻辑视图：说明能力域划分与闭环关系（管理-应用-治理-洞察）。



- 链接:../figure/figures-逻辑视图.drawio.pdf
- 开发视图：说明工程模块划分（前端入口 + 四个 SpringBoot 服务）与依赖关系。



- 链接:../figure/figures-开发视图.drawio.pdf
- 物理视图：说明部署形态与基础设施选型（存储、检索、MQ、LLM、数仓等）。




– 链接:../figure/figures-物理视图.drawio.pdf

3.2 关键流程设计（核心链路图）


下列流程图用于说明平台“从生产到应用再到治理与反馈”的端到端闭环。

- 空间与应用管理时序图：说明空间/应用创建配置与权限校验的关键交互。




– 链接:../figure/figures-空间与应用管理时序图.drawio.pdf

- 内容状态机图：说明草稿、待审批、已发布、已下线等状态与操作约束。




– 链接:../figure/figures-内容状态机图.drawio.pdf

- 内容发布流程时序图：说明“编辑-提审-审批-发布”与发布事件驱动异步链路。




– 链接:../figure/figures-内容发布事件时序图.drawio.pdf

- 索引构建流程图：说明发布后内容前置处理、切片与索引构建（全文索引与向量索引）。




– 链接:../figure/figures-索引构建流程示意图.drawio.pdf


- 智能问答流程图：说明“问题改写-多通道召回-RRF 重排-证据组织-生成-引用输出”。



- 链接:../figure/figures-智能问答完整流程图.drawio.pdf
- 重复度/歧义度检测流程图：说明“向量粗召回 + LLM 精判别”的两阶段检测。




- 链接:../figure/figures-重复度 _ 歧义度模型检测流程示意图.drawio.pdf
- 治理任务线上化流程图：说明“发现问题-任务化-处理-复检回收”的闭环。



- 链接:../figure/figures-质量治理任务线上化流程示意图.drawio.pdf
- 数据采集与指标生成链路图：说明事件采集、数仓加工与洞察查询链路。

– 链接:../figure/figures-数据采集与指标生成链路示意图.drawio.pdf




4. 详细设计（效果图 + 关键设计实现）

本节按“一个功能点 = 一张效果图 + 一段实现流程说明”的方式组织，便于直接转成 PPT 页面。

4.1 内容组织与应用配置

效果图：

- 应用管理效果图（空间下应用管理、筛选、定位）



– 文件:../figure/应用管理效果图.png

实现流程（文字说明）：

1. 定义组织边界：以“空间（Space）”作为业务隔离与成员边界，以“应用（App）”作为具体消费场景与配置边界。
2. 定义内容组织：应用内通过“类目（Category）”提供稳定的树状导航，通过“标签（Tag）”提供跨类目的灵活聚合维度。

- 3. 写入归属字段：每条内容在存储层冗余保存 `space_id`、`app_id`、`category_id` 与 `tag_ids`，保证后续检索、权限与治理都能在统一维度上聚合与过滤。
- 4. 管理动作入口：管理端提供应用筛选、定位与配置入口，用于维护内容形态开关、类目树、标签体系等场景配置。


关键细节：

- 类目树存储采用路径枚举（path）思想，支持快速子树查询，支撑目录导航与筛选性能。
- 该组织结构贯穿“管理-应用-治理-洞察”四域，是后续所有链路的范围约束基础。

4.2 内容生产、审批与发布口径


效果图：

- 文章列表效果图（类目树导航、筛选条件与列表管理）




— 文件:../figure/文章管理效果图.png

- 文章创编效果图（统一编辑入口与正文编排）



- 文件:../figure/文章创编效果图.png
- 发布申请效果图 (提审/审批入口与状态流转)



- 文件:../figure/发布申请效果图.png

实现流程（文字说明）：

- 1. 内容建模：平台以统一内容实体承载公共元数据，不同内容形态（文章/问答/课程/案例）的差异字段落在子表或文档库中，做到“统一口径 + 差异扩展”。
- 2. 草稿与编辑：内容先进入草稿态，允许迭代编辑；草稿不进入对外可见口径，避免未审内容被检索/问答召回。
- 3. 提审与审批：内容进入待审批态后冻结对外口径，审批通过后进入已发布态；审批驳回则回到可编辑态并保留意见。
- 4. 发布事件：内容发布时产生标准化“发布事件”，通过消息队列触发异步链路（全文索引更新、向量切片索引更新、统计回收等），保证主链路低延迟。

关键细节：

- “已发布”是所有对外读链路（门户/搜索/问答）的唯一口径，避免草稿/审批中内容造成口径漂移。
- 发布链路与索引更新解耦，依赖消息队列实现异步一致性与可扩展吞吐。

4.3 页面化展示与搜索（门户/列表/筛选）

效果图：

- 典型前台界面效果图（统一搜索入口 + 多类内容聚合展示）



— 文件:../figure/前台界面效果图.png

实现流程（文字说明）：

- 1. 列表/搜索走索引：列表页、类目页、标签页、搜索页优先查询 Elasticsearch 索引，避免数据库复杂查询与全表扫描。

2. 过滤前置：将状态（仅已发布）、类目、标签、内容形态、以及权限条件转为 Filter 子句，与倒排索引交集运算得到候选集合，保障分页稳定且无“后置过滤分页空洞”。
3. 详情强一致：列表返回内容 ID 后，再批量回查数据库/缓存获取最新标题、摘要与状态；详情页按内容形态加载对应结构字段或正文，保证最终展示的强一致性。

关键细节：

- “索引圈选 + DB 兜底”的读写分离策略：性能由索引保证，一致性由 DB 回查保证。
- 权限参与索引过滤：避免应用层后置过滤导致分页结果变稀疏、用户体验不稳定。

4.4 智能问答（RAG：改写、召回、重排、引用）

效果图：

- 智能问答效果图（回答 + 引用溯源呈现）

✦ 智能总结

八大人群是基于城市层级、年龄、消费等级等维度划分的消费群体，具体包括：

1. **小镇青年**：四线及以下城市小于 35 岁群体 ¹ ²。
2. **小镇中老年**：四线及以下城市大于 35 岁群体 ¹。
3. **Z 世代**：三线及以上城市小于 25 岁年轻群体 ¹。
4. **精致妈妈**：三线及以上城市 25-35 岁备孕 / 已生性，消费等级中高及以上 ¹ ²。
5. **新锐白领**：三线及以上城市 25-35 岁白领、IT、体，消费等级中高 ¹ ²。
6. **资深中产**：三线及以上城市 36-50 岁白领、IT、体，消费等级中高 ¹ ²。
7. **都市蓝领**：三线及以上城市 25-35 岁消费等级低 ¹ ²。
8. **都市银发**：三线及以上城市大于 50 岁群体 ¹ ²。

共有2篇参考知识

- ¹ 八大人群中对应的年龄段分别是多少？
- ² 八大人群指的是什么？

以上内容为AI基于平台相关知识生成，仅供参考

– 文件:../figure/智能问答效果图.png

实现流程（文字说明）：

1. 问题改写：对用户原始 Query 做结构化改写（提取对象/场景/诉求），输出更贴近知识标题与正文的检索表达，提升召回稳定性。
2. 多通道召回：并行执行两路召回：
 1. 全文通道 (ES)：适合命中专有名词、错误码、规则编号等显式关键词，并天然支持过滤条件。
 2. 向量通道 (Milvus)：适合语义改写与口语化表达，提升长尾覆盖，同样支持基于元数据的过滤。
3. 候选融合去重：将两路候选按“切片/内容”的唯一标识去重，避免重复证据污染上下文窗口。
4. RRF 重排：对每路候选按名次分配倒数排名分值并累加，得到融合分数后排序输出 TopN 证据集合。
5. 证据组织与生成：将 TopN 证据（含 Title/Text/Key 等标准字段）注入提示词，生成回答并返回“可映射引用”，保证回答可追溯到具体内容与切片。

关键细节（需要在 PPT 中讲清楚）：


- RRF 的工程口径：对每个通道内排名为 **rank** 的候选赋分 $1 / (\text{rank} + k)$ ，本文实现采用平滑常数 $k=60$ ；同一候选在多通道的分值相加作为最终融合分数。
- 关键参数含义：
 - TopK：单通道召回候选上限，用于控制延迟与后续开销。
 - MinScore：低相关候选过滤阈值，用于提升精度与可解释性。
 - TopN：最终证据数量，受上下文窗口与引用展示约束。
- 输出的引用必须能映射到 **content** 与 **slice**：这是后续治理与问题定位的入口条件。

4.5 内容治理闭环（发现、任务化、处理、复检回收）

效果图：

- 治理任务线上化效果图（治理工单、分发、状态跟踪）

— 文件:../figure/治理任务线上化效果图.png



实现流程（文字说明）：

- 1. 问题发现：围绕重复度、歧义度、覆盖度三类质量问题产出“问题候选”。
- 2. 重复/歧义检测两阶段：
 - 1. 候选召回：先用向量检索缩小比对范围（从全量两两比对降到局部邻域）。
 - 2. 精判别：再用大模型对候选对做深语义比对，判定“重复”或“歧义（口径冲突/表述矛盾）”，并输出结构化依据。
- 3. 覆盖度检测机制：以真实会话日志为输入，对未命中或低质量命中的 Query 做语义聚类形成问题簇；对代表性 Query 判别覆盖情况，若未覆盖则生成“缺知识”任务。
- 4. 任务线上化：将结果转为“主任务（Batch）-子任务（Item）”两层工单：
 - 1. 主任务记录一次治理的范围与版本（空间、时间窗口、算法版本等）。
 - 2. 子任务对应可执行实体（重复/歧义的内容对；覆盖度的问题簇）。
- 5. 处理与回收：人工处理后子任务先进入“已处理待复检”；系统按日巡检查复，仅当问题消除后才自动关闭任务，确保治理有效。


关键细节：

- 幂等创建：任务生成以“任务类型 + 实体标识”为唯一约束，避免重复生成导致治理噪声。
- 状态口径：主任务（新建/运行中/完成），子任务（待处理/处理中/已处理/已关闭），保证治理可追踪、可统计。
- 治理动作要与内容发布链路打通：处理产生的内容修订/下线，必须经发布事件驱动索引更新，保证结果在检索/问答侧可见。

4.6 数据洞察（会话分析与链路追踪）

效果图：

- 会话分析效果图（指标汇总 + 问题簇下钻）



– 文件:../figure/数据洞察——会话分析效果图.png

实现流程（文字说明）：

1. 统一事件模型：页面化链路采集曝光/点击/搜索等事件；问答链路采集召回、重排、生成、转人工等事件，均携带统一公共维度字段。
2. 双标识追踪：
 1. `session_id`：组织多轮交互与漏斗分析。
 2. `trace_id`：贯穿单轮问答的召回-重排-生成关键节点，用于端到端还原证据与决策链路。
3. 数仓加工：事件进入数仓侧加工为明细表与指标宽表，洞察模块提供只读查询接口与权限控制。
4. 结果下钻：洞察侧支持“宏观指标趋势 -> 聚类级主题 -> 会话明细 -> 引用证据”的分析路径，用于定位高频问题与薄弱点，并反哺覆盖度治理与策略优化。

关键细节：

- 事件字段需同时覆盖“范围维度（space/app）”与“内容维度（content/slice）”，否则无法做到从效果到内容的可回溯闭环。
- 采集接入层对（`trace_id`，`event_name`）做幂等去重，避免指标膨胀。